

위험 소리 식별 기술개발을 위한 효과적인 CNN 기반 학습모델의 실험적 비교

김도균*, 이준영**, 하옥균***

An Experimental Comparison of Effective CNN-based Learning Models for Developing Hazard Sound Identification Technology

DoGyun Kim*, JunYeong Lee**, and Ok-Kyoon Ha***

요 약

본 논문에서는 딥러닝 기술을 이용하여 실내외에서 발생하는 위험소리를 식별하는 학습모델의 개발을 위해 10종의 소리 데이터를 2D-CNN 기법으로 학습하여 개발된 딥러닝 학습모델을 대상으로 소리 데이터의 두 가지 정규화 방법에 따른 정확성의 비교와 경량화를 위한 각 양자화에 따른 효과성을 실험적으로 비교한다. 실험 결과 MFCC 정규화 방법을 적용한 모델이 Mel-Spectrogram 방법에 비해 개선된 정확성을 보이고, 3가지 양자화 방법들 중 Float16 양자화 방법이 원본 모델에 비해 약 17%의 용량만으로 유사한 정확성을 보인다.

Abstract

This paper addresses the development of a deep learning model for identifying hazardous sounds occurring in both indoor and outdoor environments using deep learning techniques. In this study, a deep learning model is trained on a dataset comprising 10 types of sound data using a 2D-CNN technique. The study experimentally compares the accuracy of the model based on two different sound normalization methods for data preprocessing and evaluates the effectiveness of various quantization techniques for model compression. The experimental results demonstrate that the model utilizing the MFCC normalization method achieves improved accuracy compared to the Mel-Spectrogram method. Among the three quantization methods tested, the Float16 quantization reduces the model size to approximately 17% of the original while maintaining similar accuracy.

Key words

shape recovery, shape from focus, artificial neural network, depth estimation, focus measure

1. 서 론

현대사회에서 다양한 요인으로 인해 청각장애인과 난청인이 증가하고 있고 이들은 일상 및 직업

생활에서 비장애인 및 비난청인에 비해 수용할 수 있는 정보의 제한으로 인해 안전사고 등의 위험 정보 획득에 어려움을 겪고 있다[1]. 이러한 문제를 해결하기 위해 주변의 위험소리를 딥러닝 기술로

*경운대학교, 201905060@ikw.ac.kr, **경운대학교, dlwnsdud1206@naver.com, ***경운대학교 okha@ikw.ac.kr(교신저자)

식별하여 사용자에게 시각화 또는 진동으로 알려주는 기술이 제시되고 있다.

스마트 폰, 스마트 워치, 스마트 Hub 등의 임베디드 장치에 탑재되는 기존의 방식들을 위해서 본 연구에서는 딥러닝 학습에 필요한 소리 데이터의 전처리를 위한 2가지 정규화 방법과 더불어 정확성의 손실을 최소화하는 경량화 방법을 실험적으로 비교하였다. 실험 결과 MFCC 정규화 방법을 적용한 학습모델이 Mel-Spectrogram 방법을 적용한 모델에 비해 평균 약 2.5% 개선된 정확도를 보인다. 또한, 3가지 양자화 방법을 적용하여 학습모델을 경량화한 결과의 비교에서는 Float16 양자화를 적용한 경우 원본 모델에 비해 약 17%의 파일 크기만으로 약 7%만 감소된 정확도를 보인다. 이러한 결과는 스마트 폰과 같은 저사양 장치에 본 학습모델을 적용하여 청각장애인 및 난청인을 위한 서비스 개발에 유용하게 활용할 수 있을 것으로 기대한다.

II. 연구 방법

CNN과 같은 딥러닝을 통해 소리 신호의 특징을 추출하는 기법에는 소리 신호를 일정 구간으로 나누어 구간별 스펙트럼을 분석하여 특징점을 추출하는 Mel-Frequency Cepstral Coefficients (MFCC) 방법이 대표적이다 [2, 3]. MFCC는 Mel Spectrum에서 Cepstral 분석을 통해 추출된 값을 의미하며, 소리 신호를 프레임별로 고속 푸리에 변환(FFT)를 적용해 생성된 배음 구조의 차이를 포함하는 Spectrum에 물리적인 주파수와 실제 사람이 인식하는 주파수의 관계에 기반한 Filter Bank를 적용하여 도출한 Mel Spectrum을 대상으로 Cepstral 분석을 적용해 추출된다. 이때 Cepstral 분석은 소리 주파수의 피크 값들의 연결 곡선과 Spectrum을 분리하는 것으로 Discrete Cosine Transform (DCT)를 취한 값에서 계수를 구한 결과이다. Mel-Spectrogram은 음성 신호를 시각적으로 변환하는 방법으로, 음성 인식이나 음향 분석과 같은 기계 학습 작업에 유용하게 사용된다.

이 방법은 음성 신호를 단시간 푸리에 변환(STFT)을 적용해 짧은 프레임으로 나누어 시간에

따른 주파수 정보를 인간의 청각을 반영한 멜(Mel) 스케일로 변환된다. 이를 통해 결과적으로, x축은 시간을, y축은 주파수를, 색 강도는 진폭을 나타내는 스펙트로그램(Spectrogram)이 생성된다. 멜 스케일을 사용함으로써 스펙트로그램은 인간의 음성이나 음향 분석 작업에 더 적합해 지기 때문에 이를 통한 최종 출력은 소리를 2D 이미지로 표현한 형태로 변형되어 CNN과 같은 모델에 입력 데이터로 쉽게 활용할 수 있다.

본 연구에서는 딥러닝 기반 CNN 모델을 활용하여 위험 소리를 식별하기 위한 소리 데이터를 전처리한 후, 학습 모델을 개발하고 경량화를 통해 효율성을 개선하는 과정을 실험적으로 검토한다. 실험은 두 가지 정규화 방법(MFCC, Mel-Spectrogram)과 세 가지 양자화 방법을 적용한 모델을 통해 진행하며, 이를 바탕으로 모델의 정확성과 파일 크기, 추론 시간을 비교한다. 그리고, 실험에 사용할 소리 데이터는 표 1과 같이 10종(경적, 유리깨짐, 비명, 경보, 도난, 화재, 응급, 가스누출, 폭발, 충격)의 소리를 AI 허브 및 국내 빅데이터 사이트 등의 인터넷 수집을 통해 총 3,512개를 확보하여 실험에 사용한다.

표 1. 실험 데이터 세트

단위(개)

Table 1. Experimental data sets

경적	유리 깨짐	비명	경보	도난	화재	응급	가스 누출	폭발	충격
400	400	358	400	277	300	300	320	400	357

III. 비교 실험

실험을 위해 학습할 소리 신호 데이터를 모노타입으로 통일하고 다른 Sampling Rate를 Re-Sampling 하여 22,050Hz로 통일하여 Bit Depth를 정규화하는 과정을 거쳤다. 이러한 MFCC와 Mel-Spectrogram으로 추출된 각 데이터를 구분하고 Conv2D 4-layer, Max_pooling2D 3-layer, Global_average_pooling2D 1-layer, Dense 3-layer로 구성된 단일 CNN 모델을 적용하여 학습에 사용하였다.

단일 CNN 모델을 적용하여 두 분류의 데이터 집합을 비교한 실험 결과 MFCC 정규화 기반의 데이터를 적용한 경우 학습 초기에 정확도가 빠르게

상승하였으며, 최종적으로 훈련 정확도 99.57%, 검증 정확도 97.65%를 기록하였다. 반면, Mel-Spectrogram 정규화 모델은 상대적으로 느린 학습 곡선을 보였으며, 최종적으로 훈련 정확도 98.36%, 검증 정확도 96.30%를 기록하였다. 최종적으로, MFCC 정규화 데이터를 사용한 CNN 모델이 평균적으로 약 2.5% 더 높은 정확도를 보였으며, 이는 MFCC가 소리 특징을 더 효과적으로 추출함을 시사한다.

한편, 스마트 폰, 스마트 워치, 스마트 Hub 등의 임베디드 장치에 탑재되는 기존의 방식들을 위해서 학습 모델의 경량화의 필요성이 증가하는데, 이를 위해 MFCC 기반 데이터를 학습한 모델을 대상으로 양자화(Quantization) 기반의 경량화를 적용하여 파일 크기, 응답시간, F1-Score 기반의 정확도를 실험하여 비교하였다.

표 2. 양자화에 따른 실험 결과

Table 2. Experimental results according to quantization

Model name	File size (MB)	Inference Time (sec)	F1-Score
original (HDF5)	285.3	1.15	0.98
Full int quantized	24.6	0.63	0.003
Float16 quantized	47.4	0.58	0.91
Dynamic Range quantized	24.4	0.63	0.84

실험 결과는 표 2에서 보인것과 같이 원본 모델 (HDF5)은 285.3MB 크기를 차지하며, 추론 시간은 1.15초로 나타났다. 양자화를 적용한 학습모델은 평균 32.1MB 크기로 줄어들었고, 응답시간도 평균 0.61초로 단축된 반면, 정확도는 평균 58.4%로 크게 감소된 결과를 보였다. 이들 양자화를 통한 경량화 방법 중 Full int quantized 방법을 적용한 모델은 파일 크기가 24.6MB로 줄었으며, 추론 시간도 0.630 초로 감소하였으나 정확도가 0.003을 기록하여 정확도의 손실이 매우 심각한 결과를 보였다. Float16 quantized 방법을 적용한 경량화 모델은 파일 크기 47.4MB, 추론 시간 0.585초로 가장 빨랐고, F1-Score는 0.91로 원본 대비 약 7%의 정확도 손실을 보였다. 마지막으로 Dynamic Range quantized 모델은 Full int 양자화와 유사한 성능을 보였으며, F1-Score

가 0.84로 원본 대비 14%의 정확도 손실을 보였다.

결론적으로 모든 양자화 방식에서 원본 모델 대비 파일 크기와 추론 시간이 크게 감소했음을 확인할 수 있었으며, Full int quantized 방법을 제외한 두 가지 방법에서 낮은 정확도 손실로 경량화할 수 있는 것으로 확인되었다. 특히 Float16 양자화 모델의 경우 약 7%의 정확도 감소만으로 파일 크기를 약 83%로 줄이면서도 추론 시간을 50% 이상 단축시켜 스마트폰 등의 임베디드 시스템을 위한 경량화 방법으로 가장 우수한 결과를 보였다.

III. 결 론

본 연구에서는 위험 소리를 식별하기 위한 딥러닝 모델을 개발하고, 두 가지 정규화 방법(MFCC, Mel-Spectrogram)과 세 가지 양자화 방법의 성능을 실험적으로 비교하였다. 실험 결과, MFCC 정규화 방법을 적용한 모델이 Mel-Spectrogram 방식에 비해 더 높은 정확도를 보였으며, 경량화 실험에서는 Float16 양자화가 파일 크기를 약 83% 줄이면서도 원본 모델과 유사한 정확성을 유지하였다. 이러한 결과는 소리 식별 모델이 스마트폰 및 스마트워치와 같은 저사양 임베디드 장치에서도 효율적으로 적용될 수 있음을 시사한다. 특히, 청각장애인 및 난청인을 위한 위험 소리 식별 서비스의 실시간 제공에 큰 기여를 할 수 있을 것으로 기대된다.

참 고 문 헌

- [1] 이현아, 이준우, "청각장애인의 위험 판단을 위한 소리 정보, 인지 조건과 행동 반응에 관한 연구", 한국장애인복지학, 38(38), 149-180, 2017.
- [2] Abdelmajid H. Mansour, Gafar Zen Alabdeen Salh, Khalid A. Mohammed, "Voice Recognition using Dynamic Time Warping and Mel-Frequency Cepstral Coefficients Algorithms," *Inter. Journal of Computer Applications*, 116(2), 34-41, April, 2015.
- [3] 윤원정, "MFCC를 활용한 딥러닝 기반 음성 인식 모델에 관한 연구." 국내석사학위논문 한세대학교 대학원, 2022.